

# MPEI 2023-2024

Variáveis aleatórias  
multidimensionais

# Motivação

- Trabalhamos frequentemente com grupos de variáveis relacionadas

120 million photoreceptors



256 EEG sensors



- Exemplo:
  - **Peso e altura** das pessoas
  - 256 valores medidos por sensores ECG

# Variáveis aleatórias multidimensionais

- Frequentemente temos situações em que os resultados possíveis são conjuntos de várias variáveis aleatórias,  $X_1, X_2, \dots$
- Dois tipos de casos:
  - Experiência aleatória produz várias saídas
  - Repetições da experiência aleatória (com uma única saída)
- A um vector n-dimensional em que as componentes são as variáveis aleatórias  $X_1, X_2, \dots, X_n$  chama-se **vector aleatório** ou **v.a. Vectorial**

$$\mathbf{X} = (X_1 \quad X_2 \quad \dots \quad X_n) \hookrightarrow (x_1, x_2, \dots, x_n)$$

# Vector aleatório

- **Um vector aleatório**  $X$  é uma **função que atribui um vector de números reais** a todos os resultados  $\zeta$  no espaço de amostragem da experiência aleatória  $S$
- Exemplo:  $\mathbf{X} = (H \ W \ A)$  com

$H(\zeta)$  = altura do estudante  $\zeta$  em metros,

$W(\zeta)$  = peso do estudante  $\zeta$  em Kg, e

$A(\zeta)$  = idade do estudante  $\zeta$  em anos.

Para 1 v.a.:

$P_X(x)$ : função massa de probabilidade  
 $F_X(x)$ : função de distribuição  
 $E[X]$ : valor esperado

# Como caracterizar estas variáveis aleatórias com n-dimensões ?

# Funções de distribuição conjuntas

- Para situações envolvendo 2 ou mais variáveis, definem-se, estendendo as definições para uma variável:
  - Função massa de probabilidade conjunta
  - Função de distribuição cumulativa conjunta
  - Função de densidade de probabilidade conjunta

# Função massa de probabilidade conjunta

- Para duas variáveis discretas,  $X$  e  $Y$ :

variáveis aleatórias

↓                      ↓

- $p_{X,Y}(i, j) = P(X = i \wedge Y = j)$

↑                      ↑  
respetivos probabilidades

- Exemplo:  $X$ = dado 1;  $Y$ = dado 2


$$p_{X,Y}(1,1) = p_{X,Y}(1,2) = \dots = p_{X,Y}(6,6) = 1/36$$

↑                      ↑  
Dado 1                  Dado 2



# Exemplo (continuação)

- Representação 3D





# Função massa de probabilidade conjunta

- A expressão **generaliza para mais de 2 variáveis**:
- $$p_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n)$$
- Uma função em  $\mathbb{R}^n$ , não-negativa
- $\sum_{x_1, x_2, \dots, x_n} p_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = 1$



# Função de distribuição acumulada conjunta

- Simples extensão ...
- Para duas variáveis,  $X$  e  $Y$ :

$$F_{X,Y}(x, y) = P(X \leq x \wedge Y \leq y)$$

- Para  $n$  variáveis:

$$F_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n).$$

No caso discreto é uma função em terraços ...

# Exemplo 1

- Caso discreto

$Y_1 =$  número de temporais em Junho (0, 1, ou 2)

$Y_2 =$  número de temporais in Julho (0, 1, ou 2)

- Tabela com probabilidades

		Julho ( $y_2$ )		
Junho ( $y_1$ )		0	1	2
	0	0.05	0.1	0.15
	1	0.1	0.15	0.20
	2	0.15	0.05	0.05

$p_{y_1 y_2} (0, 2)$



# Distribuição de cada uma das variáveis

- A distribuição acumulada de cada uma das variáveis pode ser obtida da distribuição conjunta

$$\begin{array}{l} \uparrow p_{xy}(x,y) = P[X=x, Y=y] \\ \quad p_x(x) = P[X=x] \end{array}$$

- Por exemplo, no caso com duas variáveis  $X$  e  $Y$ :

- $$\begin{aligned} F_X(a) &= P(X \leq a) \\ &= P(X \leq a, Y < \infty) \\ &= F_{X,Y}(a, \infty) \end{aligned}$$

- De forma similar:

$$F_Y(b) = P(Y \leq b) = F_{X,Y}(\infty, b)$$

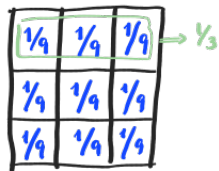


# Distribuição de cada uma das variáveis

- Também se pode obter facilmente a função de massa de probabilidade de cada uma das variáveis
- Para o caso discreto temos:

$$p_X(x) = \sum_y p_{X,Y}(x, y) \rightarrow \text{Somando todos!}$$

• Probabilidades marginais



1/9	1/9	1/9
1/9	1/9	1/9
1/9	1/9	1/9

$$p_Y(y) = \sum_x p_{X,Y}(x, y)$$

Em matlab:

$$p_y = \text{sum}(H)$$

$$p_x = \text{sum}(H, 2)$$

# Funções de probabilidade marginais

- No caso de duas variáveis ( $X$  e  $Y$ ):
- Para obter a função massa de probabilidade de  $X$  somamos as linhas apropriadas da tabela representando a função de probabilidade conjunta
- De forma similar obtém-se  $Y$  somando as colunas



# Exemplo 1

- Para o exemplo introduzido antes..

		Julho ( $y_2$ )			
Junho ( $y_1$ )		0	1	2	$p(y_1)$
	0	0.05	0.1	0.15	0.30
	1	0.1	0.15	0.20	0.45
	2	0.15	0.05	0.05	0.25
	$p(y_2)$	0.30	0.30	0.40	1.00

$$\Rightarrow P(Y_1 \wedge Y_2) = P(Y_1) \times P(Y_2)$$

$$p_{Y1}(y1) =$$

$y_1$	$p_{Y1}(y_1)$
0	0.30
1	0.45
2	0.25
TOTAL	1.00

Obrigatório!

$y_2$	$p_{Y2}(y_2)$
0	0.30
1	0.30
2	0.40
TOTAL	1.00

# Generalização

- O caso de  **$n$  variáveis discretas** é uma generalização simples
- Se  $X_1, X_1, \dots, X_n$  são variáveis aleatórias discretas no mesmo espaço de amostragem com função massa de probabilidade conjunta:

$$p_{X_1, \dots, X_n}(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n)$$

- A função de probabilidade marginal para  $X_1$  é:

$$p_{X_1}(x_1) = \sum_{x_2, \dots, x_n} p_{X_1, \dots, X_n}(x_1, \dots, x_n)$$

- A função (bidimensional) para a função de probabilidade marginal de  $X_1$  e  $X_2$  :

$$p_{X_1 X_2}(x_1, x_2) = \sum_{x_3, \dots, x_n} p_{X_1, \dots, X_n}(x_1, x_2, x_3, \dots, x_n)$$

*Não é o assunto mais importante!*





# Independência

- Em termos de função de distribuição acumulada conjunta:

$X$  e  $Y$  são independentes se e só se  $\iff$

$$F_{X,Y}(a, b) = F_X(a)F_Y(b)$$

qualquer que sejam  $a$  e  $b$

- Também, no caso discreto,  $X$  e  $Y$  são independentes **se e só se**

$$p(x, y) = p_X(x) p_Y(y)$$

- E no caso contínuo  $f_{XY}(x, y) = f_X(x) f_Y(y)$

# Generalização – independência de $n$ variáveis aleatórias

- $n$  variáveis  $X_1, X_2, \dots, X_n$  são independentes se

$$f_{X_1, X_2, \dots, X_n}(x_1, x_2, \dots, x_n) = \prod_{i=1}^n f_{X_i}(x_i), \quad \forall x_1, \dots, x_n \in \mathbb{R}$$

$\uparrow$   
Produtos

# Exemplo 1

- $Y_1$  e  $Y_2$  são independentes ?

		Julho ( $y_2$ )			
Junho ( $y_1$ )		0	1	2	$P(y_1)$
	0	0.05	0.1	0.15	0.30
	1	0.1	0.15	0.20	0.45
	2	0.15	0.05	0.05	0.25
	$f(y_2)$	0.30	0.30	0.40	1.00

↳ Não são independentes!

		Julho ( $y_2$ )			
Junho ( $y_1$ )		0	1	2	$p(y_1)$
	0	0.09			0.30
	1				0.45
	2				0.25
	$p(y_2)$	0.30	0.30	0.40	1.00


# Exemplo 2

- Consideremos sequências de 2 letras (consecutivas) em Português
  - $X_1$  representa a primeira;  $X_2$  a segunda
- Função massa de probabilidade conjunta?
- Distribuições marginais?
- $X_1$  e  $X_2$  são independentes?



# Função massa de probabilidade conjunta

Top 5:

- de
- es
- do
- ra
- es







# Distribuições marginais



# Independência

$$p(x, y) = p_X(x) p_Y(y)?$$



Não são independentes!



Diferença

# Esperança matemática



# Extensão das definições

Para 1 dimensão:  $E[X^j] = \sum x_i^j P[X = x_i]$

- Os momentos de ordem  $j, k$  das variáveis  $X, Y$  definem-se como sendo ...
- Caso discreto:

$$E[X^j Y^k] = \sum_m \sum_n x_m^j y_n^k p_{XY}(x_m, y_n)$$

- Caso contínuo:

$$E[X^j Y^k] = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} x^j y^k f_{XY}(x, y) dx dy$$

- Se  $j=1$  e  $k=0$  ou  $j=0$  e  $k=1$  temos os valores médios de  $X$  e  $Y$
- Se  $j=2$  e  $k=0$  ou  $j=0$  e  $k=2$  temos os valores quadráticos médios

# Extensão das definições (cont.)

- Os **momentos centrais conjuntos** de ordem  $j, k$  das variáveis  $X, Y$  definem-se como:

Para 1 dimensão:  $\text{Var}(X) = E[(X - E[X])^2] = E[X^2] - E[X]^2$

$$E[(X - E[X])^j (Y - E[Y])^k]$$

- Para  $j=2$  e  $k=0$  ou  $j=0$  e  $k=2$  obtemos as variâncias de  $X$  e  $Y$

Mais importante  
dos slides

# Correlação

Classificadores Naïve Bayes:

- usado em muitos algoritmos
- assumindo que os acontecimentos são independentes

- Alguns dos momentos são particularmente relevantes...

Como calcular a correlação?

2 v. a.  $X$  e  $Y$ :

- Se  $X$  e  $Y$  são independentes  
→  $E[XY] = E[X]E[Y]$

- O momento de ordem  $j=k=1$ ,  $E[XY]$ , é designado de **correlação** das variáveis  $X$  e  $Y$

- Quando  $E[XY] = 0$  as variáveis são **ortogonais**

• Como se tiverem em  
dois eixos



# $E[XY]$ e Independência

- Sendo  $X$  e  $Y$  independentes

$$E[XY] = E[X]E[Y]$$

- Demonstração (caso discreto):


$$E[XY] = \sum_{x,y} xy p_{X,Y}(x, y)$$

$$= \sum_{x,y} xy p_{X,Y}(x, y)$$

$$= \sum_{x,y} xy p(x)p_Y(y)$$

$$= [\sum_x x p_X(x)] [\sum_y y p_Y(y)]$$

$$= E[X]E[Y]$$



# Covariância

→ variação conjunta!

- A **covariância** de duas variáveis  $X$  e  $Y$  é o seu **momento central de ordem  $j=k=1$** 
  - Ou seja  $E[(X - E[X])(Y - E[Y])]$
  - Designa-se por  $\text{Cov}(X, Y)$
- $$\begin{aligned}\text{Cov}(X, Y) &= E[(X - E[X])(Y - E[Y])] \\ &= E[XY - XE[Y] - YE[X] + E[X]E[Y]] \\ &= E[XY] - 2E[X]E[Y] + E[X]E[Y] \\ &= E[XY] - E[X]E[Y]\end{aligned}$$

$\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$
- $E[X] = 0$  ou  $E[Y] = 0 \quad \Rightarrow \quad \text{Cov}(X, Y) = E[XY]$

# Covariância


- É uma **generalização da Variância**

$$\begin{aligned} Cov(X, X) &= E[(X - E[X])(X - E[X])] \\ &= Var(X) \end{aligned}$$

- A covariância é uma medida de relação linear entre as variáveis aleatórias

LINEAR: Se correlação = 0  $\Rightarrow$  poluição aumenta temperatura mantém  $\nabla$  Se < 0  $\Rightarrow$  poluição aumenta temperatura diminui  $\nabla$  Se > 0  $\Rightarrow$  poluição aumenta temperatura aumenta

- Se a relação for não linear, a covariância pode não ser sensível à relação.



# Covariância e independência

- Se  $X$  e  $Y$  são independentes então  $\text{Cov}(X, Y) = 0$

- “Demonstração”:

$$\begin{aligned}\text{Cov}(X, Y) &= E[XY] - E[X]E[Y] \\ \text{Se } X \text{ e } Y &\rightarrow \text{façam indep.} \rightarrow E[XY] = E[X]E[Y] \\ &= 0\end{aligned}$$

- Como vimos  $\text{Cov}(X, Y) = E[XY] - E[X]E[Y]$
- $X$  e  $Y$  são independentes implica

$$E[XY] = E[X]E[Y]$$

**Nota: o contrário não é verdadeiro**

pode ter-se  $\text{Cov}(X, Y) = 0$  e as variáveis não serem independentes



# Propriedades da Covariância

- $Cov(X, X) = Var(X)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(cX, Y) = c Cov(X, Y)$
- $Cov(X, Y + Z) = Cov(X, Y) + Cov(X, Z)$

Demonstração:

$$\begin{aligned} &= E[X(Y + Z)] - E[X]E[Y + Z] = \\ &= E[XY] + E[XZ] - E[X]E[Y] - E[X]E[Z] \\ &= E[XY] - E[X]E[Y] + E[XZ] - E[X]E[Z] \\ &= Cov(X, Y) + Cov(X, Z) \end{aligned}$$

- Generalização: 
$$Cov\left(\sum_{i=1}^n X_i, \sum_{j=1}^m Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m Cov(X_i, Y_j)$$



# Covariância de $n$ variáveis

- Se tivermos um vector de  $n$  variáveis aleatórias  $Y = (Y_1, Y_2, \dots, Y_n)$

- $$Cov(Y) = \begin{bmatrix} \overbrace{Cov(Y_1, Y_1)}^{var(Y_1)} & \cdots & Cov(Y_1, Y_n) \\ \vdots & \ddots & \vdots \\ Cov(Y_n, Y_1) & \cdots & Cov(Y_n, Y_n) \end{bmatrix}$$

- $$= \begin{bmatrix} Var(Y_1) & \cdots & Cov(Y_1, Y_n) \\ \vdots & \ddots & \vdots \\ \textcolor{red}{Cov(Y_1, Y_n)} & \cdots & Var(Y_n) \end{bmatrix}$$


→ Matriz triangular!  
 $Cov(Y_i, Y_m) = Cov(Y_m, Y_i)$

# Exemplo

- Considere a seguinte distribuição conjunta de  $X$  e  $Y$  e calcule  $Cov(X, Y)$

$$\begin{aligned} Cov(X, Y) &= E[XY] - E[X]E[Y] \\ &= 5.0 - 2.4 \times 2.0 \\ &= 5.0 - 4.8 \\ &= 0.2 // \end{aligned}$$

↑  
Não são independentes!



$x_i$	$P_x$
1	0.3
2	0
3	0.7
	1.0

$$\left\{ \begin{aligned} E[X] &= \sum x_i P_x[X=x_i] \\ &= 1 \times 0.3 + 0 + 3 \times 0.7 \\ &= 2.4 \end{aligned} \right.$$

$y_i$	$P_y$
1	0.3
2	0.4
3	0.3
	1.0

$$\left\{ \begin{aligned} E[Y] &= \sum y_i P_y[Y=y_i] \\ &= 1 \times 0.3 + 2 \times 0.4 + 3 \times 0.3 \\ &= 0.3 + 0.8 + 0.9 \\ &= 2.0 \end{aligned} \right.$$


$x_i$	$y_i$	$P_{X,Y}$
1	1	0.1
1	2	0.2
1	3	0
2	1	0
2	2	0
2	3	0
3	1	0.2
3	2	0.2
3	3	0.3

$$\begin{aligned} E[XY] &= \sum x_i y_i P_{X,Y}[X=x_i, Y=y_i] \\ &= 0.1 + 2 \times 0.2 + 3 \times 0.2 + 0 + 0 + 0 + 3 \times 0.2 + 3 \times 0.2 + 9 \times 0.3 \\ &= 0.1 + 0.4 + 0.6 + 1.2 + 2.7 \\ &= 5.0 \end{aligned}$$

# Cov(X,Y)= ?

- $\text{Cov}(X,Y) = E[ (X-E[X]) (Y-E[Y]) ]$
- $E(X) = ?$   
 $= 1 \times 0,3 + 3 \times 0,7 = 2,4$
- $E(Y) = ?$
- $= 1 \times 0,3 + 2 \times 0,4 + 3 \times 0,3 = 2,0$
- $\text{Cov}(X,Y) = E[ (X-E[X]) (Y-E[Y]) ]$
- $= (1-2,4)(1-2,0) \times 0,1 + (1-2,4)(2-2,0) \times 0,2$
- $+ (3-2,4)(1-2,0) \times 0,2 + (3-2,4)(2-2,0) \times 0,2$
- $+ (3-2,4)(3-2,0) \times 0,3 = 0,2$

← Por definição!



$x_i$	$p_X(x_i)$
1	0.3
3	0.7

$y_i$	$p_Y(y_i)$
1	0.3
2	0.4
3	0.3

Muito útil!

# Coeficiente de correlação

- A **coeficiente de correlação** das variáveis  $X$  e  $Y$  é:

$$\rho_{XY} = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

- Demonstra-se que  $-1 \leq \rho_{XY} \leq 1$
- E que os valores extremos (1 e -1) se obtêm para a relação linear  $Y = a X + b$  com  $a > 0$  ou  $a < 0$ , respectivamente



# Coeficiente de correlação

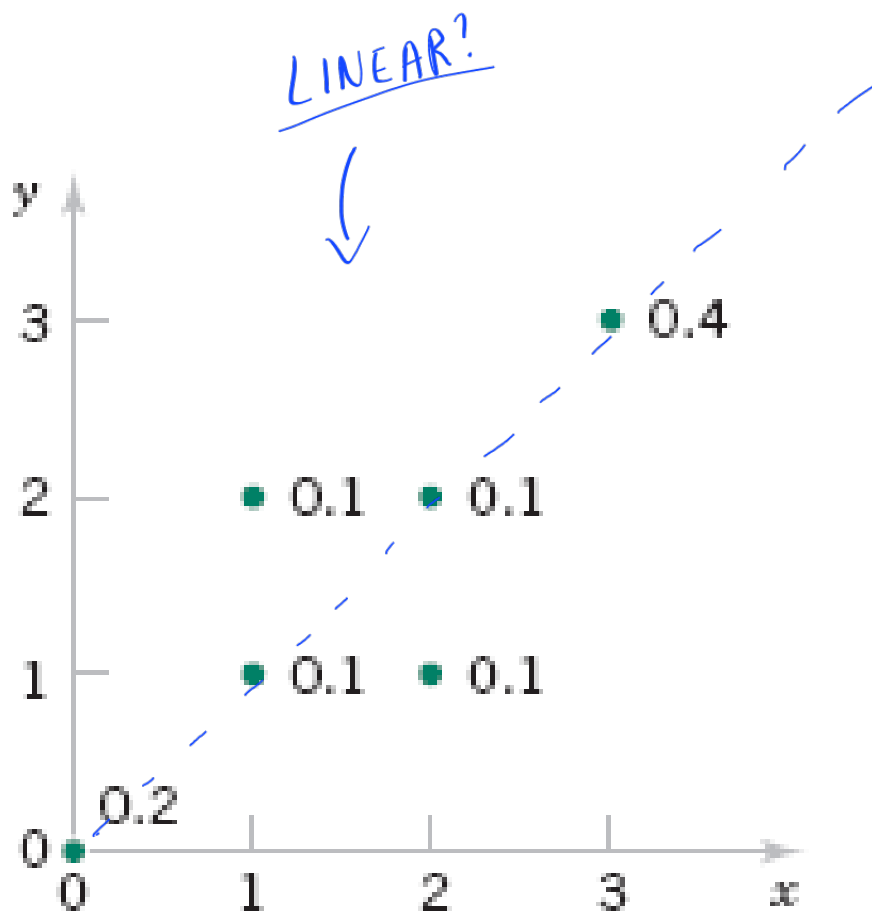
- Se  $\rho_{XY} = 0$  as variáveis dizem-se **descorrelacionadas**
- Como se viu, se  $X$  e  $Y$  são independentes, a sua covariância é nula e portanto **são descorrelacionadas**

– Mas o contrário não é (necessariamente) verdadeiro

• Não caia no erro!




# Exemplo de cálculo de $\rho_{XY}$



x	y	P(x,y)
0	0	0,2
1	1	0,1
1	2	0,1
2	1	0,1
2	2	0,1
3	3	0,4
SOMA		1,0

# Cálculo de $E[XY]$ , $E[X]$ e $E[Y]$



x	y	P(x,y)	$E[XY] = xy P(x,y)$	$E[X] = x P(x)$	$E[Y] = y P(y)$	$E[X^2] = x^2 P(x)$
0	0	0,2	$0 \times 0 \times 0,2 = 0$	0	0	0
1	1	0,1	$1 \times 1 \times 0,1 = 0,1$	0,1	0,1	0,1
1	2	0,1	0,2	0,1	0,2	0,1
2	1	0,1	0,2	0,2	0,1	0,4
2	2	0,1	0,4	0,2	0,2	0,4
3	3	0,4	3,6	1,2	1,2	3,6
	SOMA	1,0	4,5	1,8	1,8	4,6

# Exemplo de cálculo de $\rho_{XY}$

- $\text{Var}(X) = E[X^2] - (E[X])^2 = 4,6 - 3,24 = 1,36$
- $\text{Var}(Y)$  é igual à de  $X$

- $$\begin{aligned} \text{Cov}(X, Y) &= E[XY] - E[X]E[Y] \\ &= 4,5 - (1,8)(1,8) = 1,26 \end{aligned}$$



- Finalmente:

- $$\rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y} = \frac{1,26}{(\sqrt{1,36})(\sqrt{1,36})} = 0,926$$

2 v.a tem uma relação  
muito próxima de linear:  
•  $X$  aumenta  $\Rightarrow Y$  aumenta