

Cadeias de Markov

2023-2024

Problema Exemplo 1

F: "faltar à aula"

- Suponhamos que em cada dia que têm aulas de MPEI acordam e decidem se vêm ou não à aula
- Se vieram à aula anterior, a probabilidade de virem é 70% $= P(\bar{F} | \bar{F})$
- se faltaram à anterior, essa probabilidade é 80% $= P(F | \bar{F})$
- Algumas questões:
 - Se vieram à aula esta segunda, qual a probabilidade de virem na aula de **SEGUNDA** da próxima semana ?
 - Assumindo que o semestre tem duração infinita (que horror!), qual a percentagem aproximada de aulas a que estariam presentes ?

Problema Exemplo 2

- Dividir a turma em 3 grupos A, B e C no início do semestre
- No final de cada aula:
 - $\frac{1}{3}$ do grupo A vai para o B e outro $\frac{1}{3}$ do grupo A vai para o grupo C
 - $\frac{1}{4}$ do grupo B vai para A e $\frac{1}{4}$ de B vai para C
 - $\frac{1}{2}$ do grupo C vai para o grupo B
- Como ficarão os grupos ao fim de n aulas ?

↑ Podia ser a migração entre países

Exemplo 3 – “Pub Crawl”


- Bares junto a uma conhecida Universidade:



Muitas áreas de aplicação

- Muitas vezes estamos interessados na transição de algo entre certos estados
- Exemplos:
 - Movimento de pessoas entre regiões
 - **Estado do tempo**
 - Movimento entre as posições num jogo de Monopólio
 - Pontuação ao longo de um jogo
 - Estado de **Filas** de atendimento


Processos estocásticos



- Estendem o conceito de variável aleatória
- O processo estocástico **mapeia o evento para números diferentes em tempos diferentes**
- O que implica que em lugar de termos um número $X(s)$ **temos $X(t, s)$**
 - Sendo $t \in T$ geralmente um conjunto de tempos

Processos estocásticos

- 3 realizações de um processo estocástico




- Se fixarmos s , $X(t)$ é uma função real do tempo
 - $X(t, s)$ pode então ser vista como uma **coleção de funções no tempo**
- Se fixarmos t temos uma função $X(s)$ que depende apenas de s , ou seja uma variável aleatória
- Um nome alternativo é processos aleatórios

Classificação de processos estocásticos

- Podem ser classificados segundo t e os valores que pode assumir (estados do processo)
- Quanto ao tempo
 - Tempo contínuo:
 - Se tempo é um intervalo contínuo
 - Tempo discreto:
 - Se o tempo é um conjunto contável
 - Também chamada sequência aleatória e representada por $X[n]$

• Quanto ao conjunto de estados (E):

- Contínuo
- Discreto



Definição

- Um processo de Markov (de 1^a ordem) é um processo estocástico em que a probabilidade de o sistema estar num estado específico num determinado período de observação depende apenas do seu estado no período de observação imediatamente precedente
 - O futuro apenas depende do presente e não do passado

Tipos de processos de Markov

- Discretas/contínuas

| | | Espaço de estados | |
|-------|----------|---------------------------------|--------------------------------------|
| | | Discreto | Contínuo |
| Tempo | Discreto | Cadeia de Markov tempo discreto | Processo de Markov em tempo discreto |
| | Contínuo | Cadeia de Markov tempo contínuo | Processo de Markov em tempo contínuo |

- Focaremos a nossa atenção em **cadeias de Markov de tempo discreto**




Cadeias de Markov discretas

- X_n : **estado** após n transições

- Pertence a um conjunto finito,

- Em geral $\{1, 2, \dots, m\}$

- X_0 é dado ou aleatório



Questões comuns relativas a cadeias de Markov

- Qual a **probabilidade de transição entre dois estados em n observações** ?
- Existe algum **equilíbrio** ?
- Existe uma estabilidade a longo prazo ?

Propriedade de Markov

- Probabilidade de **transição do estado i para o estado j :**
- $p_{ji} = P(X_{n+1} = j | X_n = i, X_{n-1} = x_{n-1}, \dots, X_0 = x_0)$

$$= P(X_{n+1} = j | X_n = i)$$

$$\hookrightarrow p_{ji} = P(X_{n+1} = j | X_n = i) \Rightarrow p_{ji} = p_{ii}$$

- Quando estas probabilidades p_{ji} não dependem de n a cadeia diz-se **homogénea**
 - Focaremos a nossa atenção neste tipo de cadeias de Markov

Especificação de uma cadeia


- Identificar os **estados** possíveis
- Identificar as **transições** possíveis
- Identificar as **probabilidades de transição**

Aplicando ao exemplo 1 – faltar ou não faltar à aula

Sabemos que:

$$\begin{aligned} P[\bar{F}|F] &= 0.3 \\ P[F|\bar{F}] &= 0.8 \end{aligned} \Rightarrow \begin{aligned} P[F|\bar{F}] &= 0.3 \\ P[F|F] &= 0.2 \end{aligned}$$

- Estados ?



- Transições ?

- Probabilidades de transição ?

Matriz de transição:

$$T_{ji} = \begin{bmatrix} \bar{F} & F \\ \bar{F} & F \end{bmatrix} \xrightarrow{i - \text{"sabendo que"} \quad j - \text{"próximo"}}$$


Primeiro a linha
depois a coluna

Aplicando ao exemplo 1 – faltar ou não faltar à aula

- Estados ?
 - 2: {faltar, não faltar}
- Probabilidades de transição ?
 - Faltar-> não faltar : 0,8
 - Não faltar -> faltar : 0,3
- Transições ?
 - Faltar-> não faltar
 - Não faltar -> faltar
 - **Faltar -> faltar** : 0,2
 - **Não faltar -> não faltar:** 0,7

Matriz de transição

- É usual representar as probabilidades de transição através de uma matriz, **chamada de matriz de transição**
- Tendo o sistema n estados possíveis, para cada par i, j fazemos t_{ji} igual à probabilidade de mudar **do estado i para o estado j** .
- A matriz T cujo valor na posição linha $= j$, coluna $= i$ é t_{ji} é a **matriz de transição**



- Nota: Alguns autores adoptam t_{ij} como a probabilidade de mudar do estado i para o estado j



Matriz T do Exemplo 1

- $T = \begin{pmatrix} ? & ? \\ ? & ? \end{pmatrix}$
- Considerando estado 1 “não faltar”, temos
- $T = \begin{matrix} \text{não faltar} & \rightarrow (0,7 & 0,8) \\ \text{faltar} & \rightarrow (0,3 & 0,2) \end{matrix}$

Matriz T do Exemplo 2


$$T = \begin{matrix} & A & B & C \\ A & ? & ? & ? \\ B & ? & ? & ? \\ C & ? & ? & ? \end{matrix}$$

Matriz T do Exemplo 2

- No final de cada aula:
 - $\frac{1}{3}$ do grupo A vai para o B e outro $\frac{1}{3}$ do grupo A vai para o grupo C
 - $\frac{1}{4}$ do grupo B vai para A e $\frac{1}{4}$ de B vai para C
 - $\frac{1}{2}$ do grupo C vai para o grupo B

$$T = \begin{matrix} & A \\ A & \begin{matrix} 1/3 \\ 1/3 \\ 1/3 \end{matrix} \\ B & \begin{matrix} 1/4 \\ 1/2 \\ 1/4 \end{matrix} \\ C & \begin{matrix} 0 \\ 1/2 \\ 1/2 \end{matrix} \end{matrix}$$

Futuro Estado



Matriz T do Exemplo 2

| | A | B | C | |
|-----|-------|-------|-------|--|
| A | $1/3$ | $1/4$ | 0 | |
| B | $1/3$ | $1/2$ | $1/2$ | |
| C | $1/3$ | $1/4$ | $1/2$ | |



Futuro Estado

Matriz T é estocástica


- A matriz de transição reflecte propriedades importantes das probabilidades:
 - Todas as entradas são não-negativas //
 - Os valores em **cada COLUNA** somados dão sempre resultado 1
- Devido a estas propriedades a matriz é denominada de **matriz estocástica**

Representação gráfica da cadeia

- Apropriada e possível para número de estados pequeno
- Nós: representam todos os estados
- Setas: para todas as transições permitidas (one-step)
 - Ou seja, seta entre i e j apenas de $p_{ji} > 0$

Representação gráfica da cadeia

- Exemplo:



Simulação / Visualização dinâmica

- Estão disponíveis online formas de visualizar as transições entre estados ao longo do tempo ...
- Um desses exemplos é **Markov Chains - A visual explanation by Victor Powell**
 - <http://setosa.io/blog/2014/07/26/markov-chains/index.html>
- Que inclui:
 - <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.5%2C0.5%5D%2C%5B0.5%2C0.5%5D%5D%7D>
- Para usar precisamos apenas de introduzir a matriz T
 - Que define o número de estados, quais as transições possíveis e as probabilidades associadas a essas transições



Estado da cadeia num determinado instante

- O **estado** de uma cadeia de Markov com n estados no tempo (time step) k é dado pelo **vector estado**

$$\mathbf{x}^{(k)} = \begin{pmatrix} p_1^{(k)} \\ p_2^{(k)} \\ \vdots \\ p_n^{(k)} \end{pmatrix}$$

- Onde $p_j^{(k)}$ é a probabilidade de o sistema estar no estado j no instante de tempo k




Vector estado/probabilidade

- Considerando o exemplo 1:
 - Suponhamos que após 10 aulas a probabilidade de faltar e não faltar são iguais
 - Então o vector representativo do estado (*state vector*) seria:
- Também se designa por **vector de probabilidade**
 - Todos elementos não-negativos
 - Soma dos elementos igual a um

Exemplo 2

- Supondo que começávamos com:
 - 20 estudantes no grupo A e
 - 10 estudantes nos outros dois grupos
- O **vector** relativo ao **estado inicial** seria:



$$\mathbf{x}^{(0)} = \begin{pmatrix} 0,5 \\ 0,25 \\ 0,25 \end{pmatrix}$$

\uparrow
Probabilidade inicial

A horizontal timeline with two points: "Início" at 0 and "Fim" at 1. Below the timeline, there are two equations. The first equation shows the initial state $x^{(n)} = \begin{bmatrix} v_2 \\ v_3 \\ v_4 \end{bmatrix}$. The second equation shows the state after one transition $x^{(n+1)} = \begin{bmatrix} v_2 \\ v_3 \\ v_4 \end{bmatrix} \times \begin{bmatrix} t_{22} & t_{23} & t_{24} \\ t_{32} & t_{33} & t_{34} \\ t_{42} & t_{43} & t_{44} \end{bmatrix}$. A red bracket underlines the second equation, and a red box highlights the formula $x^{(n+1)} = x^{(n)} \times T_{\text{st}}$.

$$x^{(n+1)} = x^{(n)} \times T_{\text{st}}$$

Vector estado após uma transição

- Como obter $\mathbf{x}^{(k+1)}$?
- O vector de estado $\mathbf{x}^{(k+1)}$ no período de observação $k + 1$ pode ser determinado a partir do vector $\mathbf{x}^{(k)}$ através de:


$$\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)}$$

- Que resulta da probabilidade condicional:
- $P(\text{estado } j \text{ em } t = k + 1)$
 $= \sum_{i=1}^n P(\text{transição do estado } i \text{ para o } j)P(\text{estado } i \text{ em } t = k)$



Exemplo de aplicação – Exemplo 1

- De que forma depende a probabilidade de ir à aula seguinte da probabilidade de estar na aula actual ?



Estado após múltiplas transições

- Ataquemos agora problemas do “tipo”:
 - Qual a **probabilidade de transição entre dois estados em n observações/transições?**
→ “não só no dia seguinte, mas m dias a seguir”
$$x^{(k+1)} = T x^{(k)}$$
$$x^{(k+2)} = T x^{(k+1)} = T(T x^k) = T^2 x^k$$


$x^{k+m} = T^m x^k$
- Exemplo 1:
 - Qual a **probabilidade dos que estiveram na aula de uma segunda virem à aula na segunda seguinte**
 - Assumindo as probabilidades do nosso exemplo !
 - Tendo em conta que temos aulas segunda e quarta (TP1).

Probabilidade em n transições

- Definindo a transição em n passos p_{ji}^n como a probabilidade de **um processo no estado i se encontrar no estado j após n transições adicionais**. Ou seja:
- $p_{ji}^n = P(X_{n+k} = \mathbf{j} | X_k = \mathbf{i})$, $n \geq 0, i, j \geq 0$
- Obviamente $p_{ji}^1 = p_{ji}$
- E para $n > 1$?

$$p_{ji}^n$$

- É fácil de compreender se tivermos em conta que $p_{ki}^n p_{jk}^m$ representa a probabilidade de:
 - O processo ir do estado i para o estado j em $n + m$ transições..
 - Através de um caminho que o leva ao estado k na transição n
- Logo, somando para todos os estados intermédios k obtém-se a probabilidade de estar no estado j ao fim de $n + m$ transições



Equações de Chapman-Kolmogorov

- As **equações de Chapman-Kolmogorov** permitem calcular estas probabilidades

$$p_{ji}^{n+m} = \sum_k p_{ki}^n p_{jk}^m \quad \forall n, m \geq 0, \forall i, j$$

↳ posição intermédia (m passos)

Em termos de matrizes

- Se usarmos $\mathbf{T}^{(n)}$ para representar a matriz com as probabilidades de n transições, a equação anterior transforma-se em:

$$\mathbf{T}^{(n+m)} = \mathbf{T}^{(n)} \cdot \mathbf{T}^{(m)}$$

Em que o “.” significa multiplicação de matrizes


- Desta equação obtém-se facilmente:

$$\mathbf{T}^{(2)} = \mathbf{T}^{(1+1)} = \mathbf{T} \cdot \mathbf{T} = \mathbf{T}^2$$

//Provado...


O difícil no enunciado
é contar o valor de
 n^n

- E por indução $\mathbf{T}^{(n)} = \mathbf{T}^{(n-1+1)} = \mathbf{T}^{n-1} \cdot \mathbf{T} = \mathbf{T}^n$
 - Ou seja, a matriz de transição relativa a n transições pode ser obtida multiplicando \mathbf{T} por si própria n vezes




Aplicação ao Exemplo 1

- Voltando a uma questão colocada no início da aula ...
- *Se vieram à aula esta segunda, qual a probabilidade de virem na aula de SEGUNDA da próxima semana ?*



- Solução:
- Temos $\mathbf{x}^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, significando “não faltar”
- Pretendemos $\mathbf{x}^{(2)}$, 0= “esta segunda”



- $$X^{(2)} = T X^{(1)} = T(T X^{(0)}) = T^2 X^{(0)}$$

$$= \begin{pmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{pmatrix}^2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{pmatrix} \begin{pmatrix} 0.7 \\ 0.3 \end{pmatrix} = \begin{matrix} \text{F} \\ \text{F} \end{matrix} \begin{pmatrix} 0.73 \\ 0.27 \end{pmatrix}$$



- Ou seja probabilidade igual a 0.73 de virem na próxima Segunda

Terminologia

Tipos de estados


Acessibilidade de um estado

- Possibilidade de ir do estado i para o estado j (existe caminho na cadeia de i para j).



Estados comunicantes

- Dois estados comunicam se ambos são acessíveis a partir do outro.



- Um sistema é não redutível (irreducible) se todos os estados comunicam
- **Classe**: conjunto de estados que comunicam entre si




Estado recorrente

- Um estado s_i é um **estado recorrente** se o sistema puder sempre voltar a ele
 - depois de sair dele
- De uma forma mais formal:

s_i é um **estado recorrente** se, para todos os estados s_j , a existência de um inteiro r_j tal que $p_{ji}^{(r_j)} > 0$ implica que existe um inteiro r_i tal que $p_{ij}^{(r_i)} > 0$
- Um estado não recorrente é transiente

Estados recorrentes ?



- Os 3 estados são recorrentes

Estado transiente

- Um estado é transiente se existe um outro estado qualquer para o qual o processo de Markov pode transitar, mas do qual o processo não pode retornar
- Ou seja, se existe um estado s_j e um inteiro l tal que $p_{ji}^{(l)} \neq 0$ e $p_{ij}^{(r)} = 0$ para $r = 0, 1, 2, \dots$
- A probabilidade destes estados tende para zero quando n tende para infinito
 - Pois apenas são visitados um número finito de vezes


Estado periódico

- Um estado é **periódico** se apenas se pode regressar a ele após um número fixo de transições superior a 1 (ou múltiplos desse número)
- Formalizando:
 - Um estado recorrente s_i diz-se **periódico** se existe um inteiro $c > 1$ tal que $p_{ii}^{(r)}$ é igual a zero para todos os valores de r excepto $r = c, 2c, 3c, \dots$




Estado periódico

- .



Todos estados visitados em
múltiplos de 3 iterações



Todos estados visitados em
múltiplos de 3 iterações

- Um estado não periódico é **aperiódico**
– Como era de esperar!



Assuntos principais até ao momento

- Noção de processo estocástico
- Cadeias de Markov *(discutidas no tempo e no espaço)*
← Processos estocásticos que preservam a Propriedade de Markov
- Propriedade de Markov *← $(K+1)$ só depende de (K)*
- Matriz de transição T
- Representação gráfica →
 - 1 Fazer diagrama
 - 2 Fazer matriz T (*identificem os estados!*)
e os linhas e colunas
- $T^{(n)}$

Demos

- **Wolfram:**
 - **Finite-State, Discrete-Time Markov Chains**
 - <http://demonstrations.wolfram.com/ATwoStateDiscreteTimeMarkovChain/>
 - <http://demonstrations.wolfram.com/FiniteStateDiscreteTimeMarkovChains/>



O que acontece ao fim de muitas transições ?



Potências de T quando $n \rightarrow \infty$

- Exemplo 2 (3 grupos de alunos):
- Vejamos o comportamento de T^n ao aumentar n ...

$$T = \begin{pmatrix} 0.333333 & 0.25 & 0. \\ 0.333333 & 0.5 & 0.5 \\ 0.333333 & 0.25 & 0.5 \end{pmatrix}$$

$$T^4 = \begin{pmatrix} 0.17554 & 0.177662 & 0.175347 \\ 0.470679 & 0.469329 & 0.472222 \\ 0.353781 & 0.353009 & 0.352431 \end{pmatrix}$$

$$T^2 = \begin{pmatrix} 0.194444 & 0.208333 & 0.125 \\ 0.444444 & 0.458333 & 0.5 \\ 0.361111 & 0.333333 & 0.375 \end{pmatrix}$$

$$T^5 = \begin{pmatrix} 0.176183 & 0.176553 & 0.176505 \\ 0.470743 & 0.47039 & 0.470775 \\ 0.353074 & 0.353057 & 0.35272 \end{pmatrix}$$

$$T^3 = \begin{pmatrix} 0.175926 & 0.184028 & 0.166667 \\ 0.467593 & 0.465278 & 0.479167 \\ 0.356481 & 0.350694 & 0.354167 \end{pmatrix}$$

$$T^6 = \begin{pmatrix} 0.176414 & 0.176448 & 0.176529 \\ 0.470636 & 0.470575 & 0.470583 \\ 0.35295 & 0.352977 & 0.352889 \end{pmatrix}$$

A prob de estaus no estados
vão ser constantes

Continuando... (em Matlab)

% n =10


Tn =

| | | |
|--------|--------|--------|
| 0.1765 | 0.1765 | 0.1765 |
| 0.4706 | 0.4706 | 0.4706 |
| 0.3529 | 0.3529 | 0.3529 |

% n=100

Tn =

| | | |
|--------|--------|----------------------|
| 0.1765 | 0.1765 | 0.1765 |
| 0.4706 | 0.4706 | 0.4706 |
| 0.3529 | 0.3529 | <u>0.3529</u> 1.0 |



↳ Multiplicando pelo número de dados, temos uma estimativa.

Exemplo 1 (faltar/não faltar)

```
T=[0.7 0.8  
    0.3 0.2]
```

```
Tn= T;  
pij= Tn(:);  
for n=2:10
```

```
    Tn= T*Tn;       $T_n = T \times T_n$ 
```


```
    pij=[ pij  Tn(:)];
```

```
    plot(pij')
```

```
    drawnow
```

```
end
```

```
Tn
```



```
Tn =  
  
0.7273  0.7273 ←  
0.2727  0.2727 ←
```

Questões ?

- Converge ?
- Para quê ?

Equilíbrio

- As cadeias dos nossos exemplos atingem um equilíbrio.
- Quando isso acontece a probabilidade de qualquer estado torna-se constante independentemente do passo (step) e das condições iniciais
- Para analisar essa situação é necessário considerar um certo tipo de cadeias de Markov...

$$\lim_{n \rightarrow \infty} T^n$$

- Se T é a matriz de transição de um processo de Markov **regular** então:
- $\lim_{n \rightarrow \infty} T^n$ é a matriz:

$$A = \begin{bmatrix} u_1 & u_1 & \dots & u_1 \\ u_2 & u_2 & \dots & u_2 \\ \dots & \dots & \dots & \dots \\ u_N & u_N & \dots & u_N \end{bmatrix}$$

Com todas as colunas idênticas

$$\begin{aligned}
 &\xrightarrow{\text{$m \rightarrow \infty$}} \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ m \end{bmatrix} \xrightarrow{\text{Não muda}} \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ m+1 \end{bmatrix} \\
 &\Rightarrow x^{(m+1)} = T x^{(m)} \quad (x^{m+1} = x^m = u) \\
 &\Rightarrow u = T u \\
 &\vdots \\
 &\Rightarrow (T - I) u = 0 \\
 &\hookrightarrow \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ \vdots & \vdots & \vdots \\ 0 & 0 & 0 \end{bmatrix}
 \end{aligned}$$

- Cada coluna u é um vetor probabilidade em que todas as componentes são positivas

Vector estado estacionário (steady-state vector)

- Sendo T uma matriz de transição regular e \mathbf{A} e \mathbf{u} o resultado de $\lim_{n \rightarrow \infty} T^n$ (slide anterior), demonstra-se que:
 - a) Para qualquer vector de probabilidade \mathbf{x} , $T^n \mathbf{x} \rightarrow \mathbf{u}$ quando $n \rightarrow \infty$
Sendo \mathbf{u} o vector estado estacionário (**steady-state vector**)
 - b) \mathbf{u} é o único vector de probabilidade que satisfaz a equação matricial $\mathbf{T}\mathbf{u} = \mathbf{u}$
 - c) $\lim_{n \rightarrow \infty} \left(\frac{\eta(i,n)}{n} \right) = u(i)$, em que $\eta(i,n)$ é o número de visitas ao estado i em n passos (transições)

Cálculo do vector estado estacionário

- Sabemos que o vector correspondente ao estado estacionário é único.
- Usamos a equação que ele satisfaz para o calcular: $\mathbf{T}\mathbf{u} = \mathbf{u}$

- Ou, na forma matricial, $(\mathbf{T} - \mathbf{I})\mathbf{u} = 0$
↳ em matlab eye()

Exemplo 1 (aulas)

- $\mathbf{T}\mathbf{u} = \mathbf{u}$
- $\begin{bmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$
- $$\begin{cases} \frac{7}{10}u_1 + \frac{8}{10}u_2 = u_1 \\ \frac{3}{10}u_1 + \frac{2}{10}u_2 = u_2 \end{cases} = \begin{cases} \frac{-3}{10}u_1 + \frac{8}{10}u_2 = 0 \\ \frac{3}{10}u_1 + \frac{-8}{10}u_2 = 0 \end{cases}$$

$u_1 + u_2 = 1$

Não esquecer!

$u_1 + u_2 = 1 \cancel{\parallel}$
- ...

Em Matlab

Uma possível solução:

```
% matriz de transição
```

```
T=[7 8; 3 2]/10
```

```
% (T-I)u aumentado com  
u1+u2
```

```
M=[T-eye(2);  
    ones(1,2)]
```

```
%
```

```
x=[0 0 1]'
```

```
% resolver para obter u
```

```
u=M\x
```

Resultado:

0.7273

0.2727

Ou seja aprox. 72 % de probabilidade de não faltarem


Cadeias com estados absorventes

• Existem matrizes que não colaboram ...



Estado absorvente

- Um estado **absorvente** é um **estado do qual não é possível sair**
 - ou seja transitar para outro estado



- Os estados 0 e 4 são absorventes
- Uma cadeia é absorvente se tiver pelo menos um estado absorvente



Exemplo: <http://demonstrations.wolfram.com/AbsorbingMarkovChain/>


Forma canónica da Matriz de Transição

- Se numa matriz de transição **agruparmos todos os estados absorventes** obtemos a denominada forma canónica (standard form)
- O mais usual é colocar **primeiro os não absorventes** e depois os absorventes
- **A forma canónica** é muito útil para determinar as matrizes em situações limite de cadeias de Markov absorventes
 - Como veremos...



Forma canónica

- Rearranjar os estados da matriz T por forma a que os **estados transientes** apareçam **primeiro**




Q e R

- A sub-matriz Q descreve probabilidades de transição de estados não-absorventes para estados não-absorventes
- R contém as probabilidades de transição de não-absorventes para absorventes

Exemplo

- Diagrama de transição




- Matriz de transição (não canónica):
 - Estados 0, 1, 2 ...

$$\bullet \quad T = \begin{bmatrix} 1 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1 \end{bmatrix}$$

Forma canónica

- $T = \begin{bmatrix} 1 & 1/2 & 0 & 0 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 0 & 0 & 0 & 1/2 & 1 \end{bmatrix}$



$$T = \left[\begin{array}{ccccc} 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 1/2 & 0 \\ 0 & 0 & 1/2 & 0 & 0 \\ 1/2 & 0 & 0 & 1/2 & 1 \end{array} \right]$$

The matrix is partitioned into four quadrants by a green vertical line and a green horizontal line:

- Top Left Quadrant (States 1, 2, 3):** Labeled **Q**. Contains the sub-diagonal elements of the original matrix.
- Top Right Quadrant:** Contains the diagonal elements 0, 0, 1/2, 0, 1/2.
- Bottom Left Quadrant (States 0, 4):** Labeled **R**. Contains the super-diagonal elements of the original matrix.
- Bottom Right Quadrant:** Labeled **I**. Contains the 1's on the main diagonal of the original matrix.

Annotations in purple:

- A bracket labeled "Estados transientes" covers states 1, 2, and 3.
- A bracket labeled "Estados Absorventes" covers states 0 and 4.

Situação limite

Situação limite

- Como é óbvio a cadeia irá acabar por ficar indefinidamente num dos estados absorventes !
- Mas mesmo assim existem questões relevantes:
 - Qual o estado absorvente mais provável quando temos vários ?
 - Dado um estado inicial, qual o número esperado de transições até ocorrer absorção ?
 - Dado um estado inicial, qual a probabilidade de ser absorvido por um estado absorvente em particular ?

Potências de T

- Multiplicando repetidamente a matriz de transição na sua forma canónica vê-se que:

$$T^n = \begin{bmatrix} Q^n & 0 \\ X & I \end{bmatrix}$$

- A expressão exacta de X não tem interesse, mas Q e Q^n são importantes

$$Q^n$$

- A matriz Q^n representa a **probabilidade de permanecer em estados não-absorventes** após n passos
- $Q^n \rightarrow 0$ quando $n \rightarrow \infty$

$$\underset{n \rightarrow \infty}{Q^n} = 0$$

Matriz fundamental

- Multiplicando verifica-se que

$$(I - Q)(I + Q + Q^2 + \cdots + Q^n) = I - Q^{n+1}$$

- Fazendo $n \rightarrow \infty$ temos

$$(I - Q)(I + Q + Q^2 + \cdots) = I$$

– porque $Q^n \rightarrow 0$

- Isto mostra que

$$\underbrace{(I - Q)^{-1}}_{\sim} = I + Q + Q^2 + Q^3 + \cdots$$

Matriz Fundamental

$$F = (I - Q)^{-1}$$

$$= I + Q + Q^2 + \dots$$



é a **matriz fundamental** do percurso aleatório

Interpretação de F

- Sejam $X_k(ji)$ as variáveis aleatórias definidas por:

$$X_k(ji) = \begin{cases} 1, & \text{se estiver em } j \text{ após } k \text{ passos,} \\ & \text{partindo de } i \\ 0, & \text{caso contrário} \end{cases}$$

- A soma $X_0(ji) + X_1(ji) + \dots + X_n(ji)$ representa o número de visitas ao estado j , partindo do estado i , ao fim de n passos.
- O seu valor médio é dado por

$$E[X_0(ji) + X_1(ji) + \dots + X_n(ji)] = \sum_{k=0}^n E[X_k(ji)]$$

Soma dos v.a.
Iremos abordar no futuro

- Lembrar média de soma de variáveis !

Interpretação de F (continuação)

- Mas $E[\underline{X_k(ji)}] = \underline{1} \times p + 0 \times (1 - p) \overset{= p}{\underset{\text{Variável de Bernoulli}}{\approx}}$ como em qualquer variável de Bernoulli
- E p designa a probabilidade de atingir o estado j após k passos, partindo de i
 - Ou seja exactamente o valor da coluna i e linha j de $\underline{Q^k}$.
- Logo:

$$E[X_0(ji) + X_1(ji) + \cdots + X_n(ji)] = \sum_{k=0}^n Q^k(ji)$$
$$= (I - Q)^{-1}$$

Interpretação de F (continuação)

- Os elementos de $I + Q + Q^2 + Q^3 + \dots + Q^n$ exprimem portanto o **número médio de visitas ao estado j partindo do estado i em n passos**
- Logo, a **matriz fundamental F** – que é o limite dessa quantidade quando $n \rightarrow \infty$ - representa o número médio de visitas a cada estado antes da absorção
- F_{ji} dá-nos o valor esperado para o número de vezes que um processo se encontra no estado s_j se começou no estado s_i
 - Antes de ser absorvido

$$F_{ji}$$

Aplicando ao nosso exemplo

- $Q = \begin{bmatrix} 0 & 1/2 & 0 \\ 1/2 & 0 & 1/2 \\ 0 & 1/2 & 0 \end{bmatrix}$
 - $I = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$
 - $I - Q = \begin{bmatrix} 1 & -1/2 & 0 \\ -1/2 & 1 & -1/2 \\ 0 & -1/2 & 1 \end{bmatrix}$
 - $F = (I - Q)^{-1} = \begin{bmatrix} 3/2 & 1 & 1/2 \\ 1 & 2 & 1 \\ 1/2 & 1 & 3/2 \end{bmatrix}$
- "Em média podemos $\frac{3}{2}$ vezas chegando no 2"*
- "Comegando no 2 podemos em média 1 vez no 2"*
- "Comegando no 2 podemos em média 1 vez no 2"*
- "Tem o seu sentido..."*
- "Se somarmos os colunas, sabemos o número de vezes que em média chegamos estado absorvente!"*
- "Tempo médio absorvente"*
-

Tempo médio até à absorção

- O **tempo médio até à absorção** será a **soma** do número médio de visitas a todos os estados transientes até à absorção
- Ou seja a **soma da coluna i de F**

$$t_i = \sum_j F_{ji} \quad // \text{Somando a coluna!}$$

- Na forma matricial pode obter-se o vector t usando

$$t = F' \mathbf{1} \quad \text{Soma os colunas, bom para matlab}$$

- Em que :
 - $\mathbf{1}$ é uma vector coluna com uns

Tempo médio até absorção

- A soma da coluna i de F representa:
 - O valor esperado do **número de vezes que a cadeia passa por um qualquer estado transiente partindo do estado inicial i** antes da absorção
 - Valor esperado do tempo necessário até absorção partindo do estado i
- O vetor t contém os tempos médios até à absorção partindo dos vários estados transitentes

Aplicando ao Exemplo: Tempo até absorção

- $t = F' \cdot 1$

$$\begin{aligned} &= \begin{pmatrix} 3/2 & 1 & 1/2 \\ 1 & 2 & 1 \\ 1/2 & 1 & 3/2 \end{pmatrix} \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix} \\ &= \begin{pmatrix} 3 \\ 4 \\ 3 \end{pmatrix}. \end{aligned}$$

Probabilidades de absorção

- As **probabilidades de absorção** b_{ji} no estado s_j se se iniciar no estado s_i podem ser obtidas através de:

$$B = R F$$

$\begin{bmatrix} Q & O \\ R & I \end{bmatrix}$

$= {}_i^o \begin{bmatrix} 1 & 2 & 3 \end{bmatrix}$

- Em que B é uma matriz $a \times t$ com entradas b_{ji}

Aplicação ao nosso exemplo

$$B = RF$$

- Relembremos que temos:

$$T = \begin{bmatrix} 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 1/2 & 0 & 0 \\ 0 & 1/2 & 0 & 0 & 0 \\ 1/2 & 0 & 0 & 1 & 0 \\ 0 & 0 & 1/2 & 0 & 1 \end{bmatrix} \text{ e } F = \begin{bmatrix} 3/2 & 1 & 1/2 \\ 1 & 2 & 1 \\ 1/2 & 1 & 3/2 \end{bmatrix}$$

- E portanto $R = \begin{bmatrix} 1/2 & 0 & 0 \\ 0 & 0 & 1/2 \end{bmatrix}$
- Multiplicando R e F obtemos $B = \begin{bmatrix} 0 & [3/4 & 1/2 & 1/4] \\ 4 & [1/4 & 1/2 & 3/4] \end{bmatrix}$

